



强化学习入门与应用场景


具身智能产业全景与国家布局

9-10号马斯克专访：畅谈人形机器人和AI。干货满满！




具身智能产业全景与国家布局

具身智能的定义及核心三要素



注：具身智能的物理载体不一定是人形机器人 ●-----!

具身智能产业全景与国家布局



具身智能同时需要具备“本体+环境+智能”三要素。其中，本体是具身智能的物理载体，即硬件实体。它可以是机器人（如人形机器人、四足机器人、机械臂）、自动驾驶汽车等能够与物理世界交互的设备；智能是具身智能的核心，涵盖算法、模型和决策能力，它包括大模型（如视觉-语言-动作映射模型）、感知算法（图像识别、SLAM）、控制算法（运动规划、力控）等；环境是本体交互的物理世界，包括工业场景（工厂、仓库）、家庭场景（家居）、开放场景（户外、交通）等。本体通过感知模块获取环境信息 → 智能算法进行决策 → 本体执行动作影响环境 → 环境变化反馈至感知模块，形成“感知-决策-行动-反馈”循环。

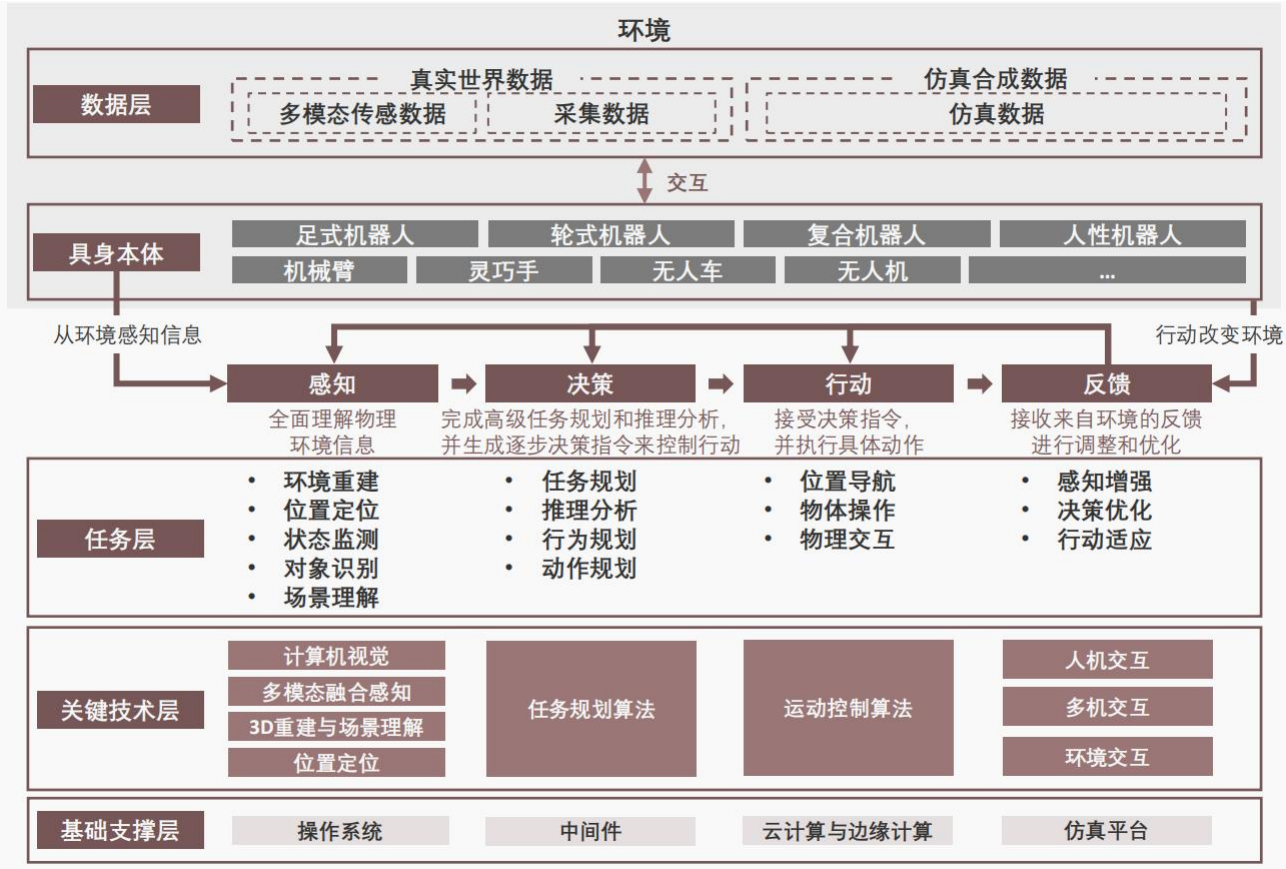
具身智能产业全景与国家布局

具身智能（Embodied Intelligence）与离身智能（Disembodied Intelligence）的核心差异在于是否依赖物理载体与环境交互。具身智能强调智能体通过身体（如机器人）与物理世界的实时交互，结合感知、决策和行动形成闭环，从而适应动态环境；而离身智能则完全依赖虚拟环境中的数据和算法，无需物理实体，仅通过抽象计算完成任务

	具身智能	离身智能
核心定义	依赖物理载体（身体）与环境实时交互，形成感知-决策-行动闭环	无物理载体，依赖虚拟环境中的数据和算法，通过抽象计算完成任务
关键特征	多模态感知（视觉、触觉、力觉等）；实时环境反馈与闭环控制；身体与环境协同进化	单一模态数据处理（如文本、图像）；抽象逻辑推理；无需物理交互
技术实现	传感器（摄像头、激光雷达等）+ 执行器（机械臂、轮子等）；强化学习、多模态大模型	深度学习、自然语言处理（如ChatGPT）；数据驱动的虚拟推理
应用场景	工业机器人（抓取、装配）；自动驾驶；医疗手术机器人；应急救援机器人	信息检索（搜索引擎）；数据分析（金融预测）；虚拟助手（Siri、Alexa）
优势	动态环境适应性强；高泛化能力（跨场景迁移）；精准物理交互（如触觉控制）	高效计算（虚拟空间快速响应）；低成本部署；跨领域通用性（如GPT-4）
劣势	硬件成本高；开发复杂度高（需解决感知-决策-行动闭环）；能耗大	缺乏物理反馈（无法操作实体）；场景局限性（仅适用于虚拟任务）；动态环境适应差
与AGI的关系	通过身体-环境闭环模拟人类智能，推动AGI发展	作为AGI的辅助工具，但因缺乏物理交互难以直接实现通用性
典型代表	 优必选-Walker S1 已在奥迪一汽和比亚迪工厂中进行实训  Apptроник-Apollo 已与NASA、奔驰、物流巨头GXO展开商业应用合作	 ChatGPT  deepseek  通义千问  豆包

具身智能产业全景与国家布局

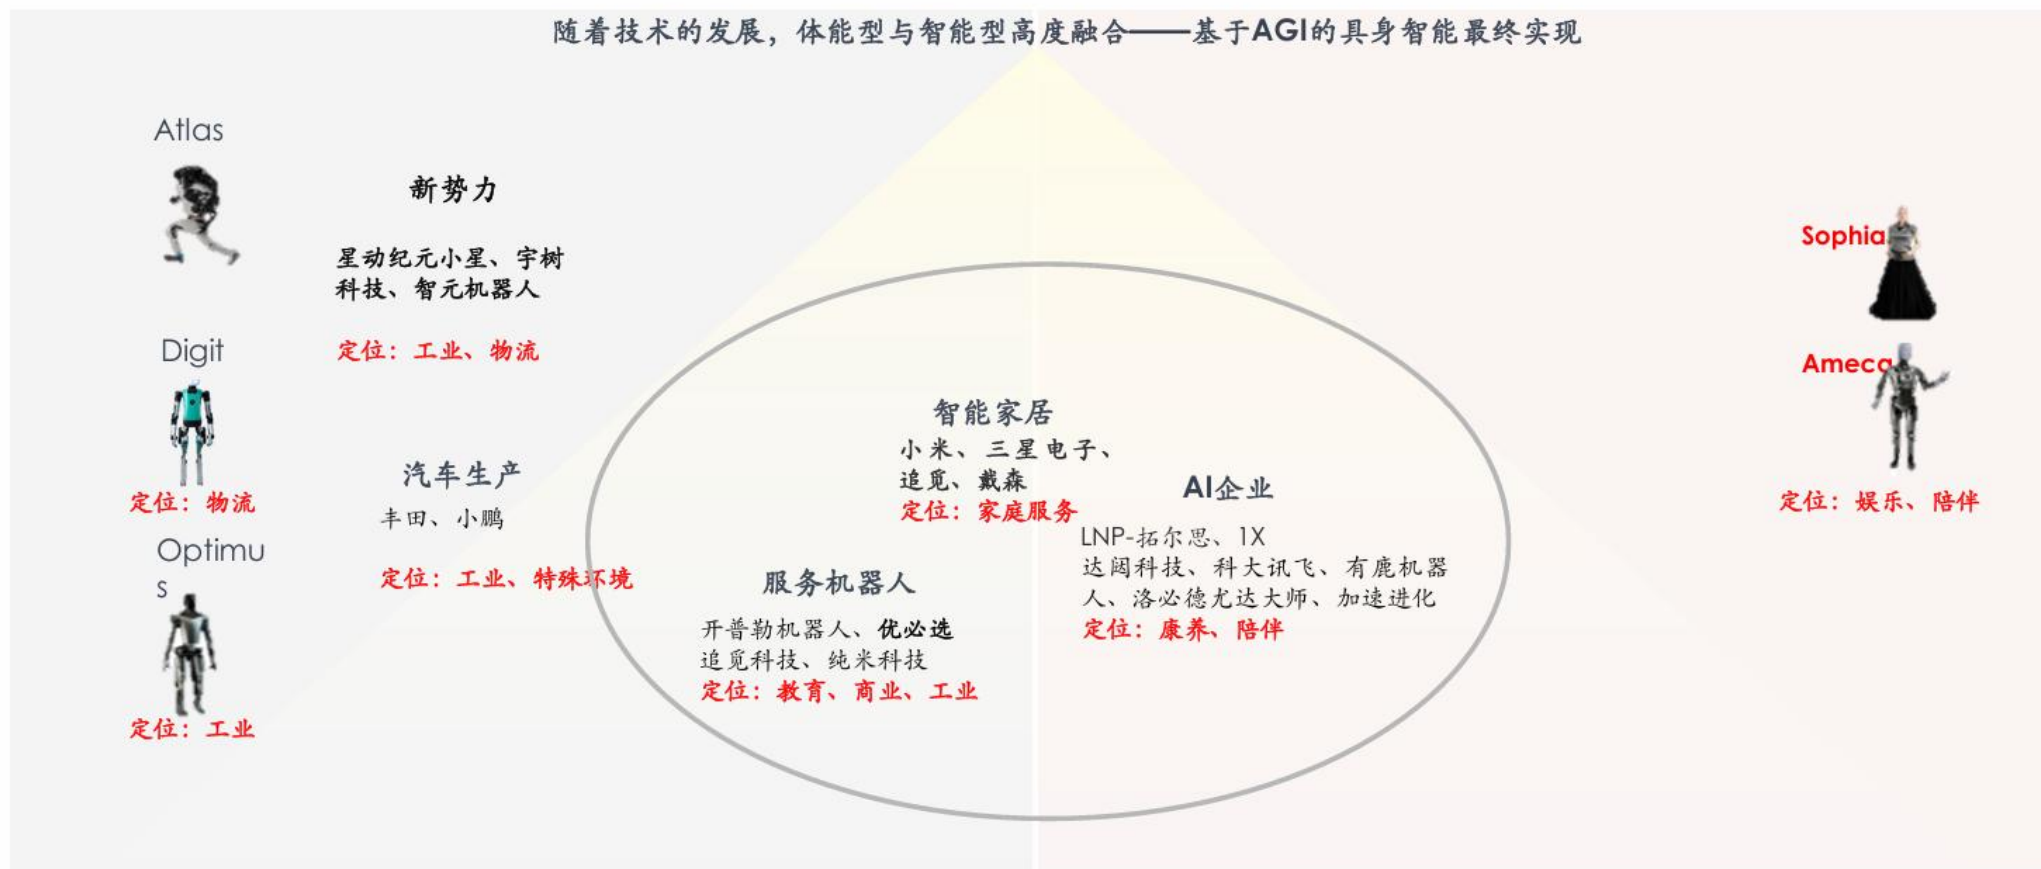
当前，具身智能的演进趋势正由分模块化的AI算法整合向基于大模型的统一技术框架转型，在跨场景泛化能力和通用性方面取得显著进展。现阶段，具身智能正处于多路径协同演进的关键阶段，技术路线涵盖感知-决策融合、感知-决策-行动全链条闭环等方向，最终目标是构建具有通用智能的具身智能基础模型，实现复杂环境下的自主演化与能力跃迁。



具身智能产业全景与国家布局

- 体能型以美国波士顿动力的Atlas, Agility 的 Digit, 特斯拉Optimus为代表；智能型以香港Hanson Robotics的Sophia 以及英国Engineered Arts的Ameca为代表；
- 从商业化定位上来看体能型产品更偏向制造业及物流领域的落地场景，而家庭、康养类的人形机器人则兼具运动及智能

随着技术的发展，体能型与智能型高度融合——基于AGI的具身智能最终实现



具身智能产业全景与国家布局

制造业和服务业对人形机器人的需求不同：制造业需要人形机器人在鲁棒性及命令执行的准确性上要求较高；而家庭服务对人形机器人的功能多样性、高度自主性以及交互的流畅性上有较高的要求。

目前受限于交互的能力及协同能力等技术的发展，人形机器人的市场渗透应该从环境相对封闭，工序相对简单且标准的场景开始，有标准的操作流程，有明确的评判标准，在自动化发展受限的情况下，替代部分的人工。因此自动化发展受限的制造工厂（如汽车的总装车间）将是人形机器人走进商业化切入的最佳场景。

人形机器人商业化落地优先从制造业开始

1. 制造业的商业化优先落地政策及产业双轮推动的首要目标；
2. 制造业的环境的相对简单及标准化的工序决定了人形机器人首先商业化落地。


指标	制造业	服务业
服务对象	物	人
应用场景	相对封闭	多样化
识别对象	少	多
路径规划	标准	复杂
突发状况	少	多
产出的一致性	高	低
工序	简单、明确	不确定性高
生产效率的测量标准	简单	复杂
质量标准	明确	难以标准化

鲁棒性、命令执行的准确性 多功能、流畅交互、高度自主


人形机器人潜在场景及需求特征	制造业 	服务业 
应用场景（潜在）	• 结构化工序（装配、检测、维护等） • 非结构化工序（人-机-环境协同） • 如汽车小型零部件总装、整车总装等，补充原有工业机器人无法实现的精细组装环节，增强人机交互能力，提升不同场景	• 提供综合家政服务（如做饭、打扫等多功能综合） • 提升人机交互可靠安全性（复杂区域引导、灵活操作、鲁棒行走、多模态人机交互）
落地潜力	• 中短期潜力较大，落地应用预计优先释放 • 目前已有人形机器人企业与车企进行联动，将汽车生产工厂作为首要落地场景，应用潜力较大	• 中短期潜力居中，人机协同技术要求较高、落地应用逐步释放 • 家政服务市场需求较大，但市场认可度待持续开发
精准度	• 制造环节为标准化流程，但对于总装等环节的细节处理要求较高	• 非标准化场合，对于人形机器人的灵活性要求高，精准度要求居中
人机交互	• 主要用于生产环节，需要有一定的人机交互能力	• 面向群体为人，对于人机交互能力要求更高
技术壁垒	• 运动控制能力，手部精细化操作能力	• 对于不同场景、不同群体适配性要求更高，模型训练及泛化能力要求更高，研发时间更长

具身智能产业全景与国家布局

- 第一阶段从制造业工厂切入：“替代相对简单且重复性的劳动”为应用标准。市场特点：产品不能执行更复杂的任务，且用户对新事物的接受程度不高，应用场景较为局限；
- 第二阶段，工厂的场景渗透加强，在产品改良持续降本的基础上人形机器人逐渐走进餐厅、商场等商业场景
- 第三阶段，AGI与人形机器人结合，最终实现具身智能，人们对人形机器人的接受程度达到顶峰，人形机器人开始走入家庭
- 技术得到革命性突破的理想状态下，M2从劳动力缺口及收入成本角度分析给出人形机器人市场规模的两种估计预测：在保守估计下，预计2024年全球市场将有千台的突破，到2030年市场规模将达7.6万台；在乐观估计下打破2030年市场规模将突破百万台。



2023~2035年全球人形机器人市场规模预测 单位：亿美元



具身智能产业全景与国家布局

具身智能商业化落地的本质是将认知智能与物理执行系统深度融合，使得具身本体能够通过感知、理解与行动协同完成任务，而其技术路径涉及到三大层面，分别是算法演化、数据来源和硬件演进

具身智能商业化的三大核心技术层面——算法、数据、硬件



具身智能产业全景与国家布局

上层控制（机器人“大脑”）

 **算法层面：**负责任务的定义与行为决策，理解物理世界中的关键特征要素，对外界环境和任务需求进行分析与拆解，并将其转化为具体的行动指令。在此背景下，**VLA（视觉-语言-动作）**模型正逐步成为实现这一能力的标准路径。

 **硬件层面：**SoC芯片——CPU、GPU、存储芯片、AI加速芯片、通信芯片等。

数据采集（驱动模型迭代）

真实数据的获取依赖遥操作系统与高精度动作捕捉；合成数据可通过域随机化机制模拟得到（如NVIDIA Omniverse）；网络视频数据则用于补充长尾行为模式。

下层控制（机器人“小脑”）

 **算法层面：**负责操作执行与运动控制，涵盖目标运动规划、末端执行器控制及全身协调控制等，具有较高的控制频率和严格的实时性要求。**MPC、WBC**等经典算法被广泛应用，且强化学习（RL）逐渐成为不确定环境下的补充路径。



 **硬件层面：**处理器、存储单元、通信接口、传感器接口、执行器接口、电源模块等。



注：以人形机器人为载体的具身智能，其“大脑”控制器通常位于躯干核心区域，“小脑”控制器通常分布在头部、四肢关节。上图仅作视觉化展示

具身智能核心技术解析

强化学习讨论的问题是智能体（agent）怎么在复杂、不确定的环境（environment）中最大化它能获得的奖励。



具身智能核心技术解析

- 状态 (S)：对环境的完整描述，不会隐藏信息
- 观测(O)：是对状态的部分描述，可能会遗漏一些信息。智能体通常获得的是观测。
- 动作(A)：智能体在环境中可以做出的动作
- 奖赏(R)：由环境给的一种标量的反馈信号

举例：<https://openai.com/research/emergent-tool-use>


具身智能核心技术解析

- 策略(π): 根据观察的状态做出决策应该采取什么动作
- 状态转移: 环境执行动作后, 得到一个新的状态
- 轨迹 (trajectory)

具身智能核心技术解析


强化训练的基本过程是这样的

- Observe state s_t , make action a_t , environment gives s_{t+1} and reward r_t .



- The agent can be controlled by either $\pi(a|s)$ or $Q^*(s, a)$.

具身智能核心技术解析




• 李世石最为人知的一战当然是2016年3月与AlphaGo的五番棋。他在第四局78手弈出“神之一手”，取得人类棋手对阵AlphaGo正式比赛中的第一局——可能也是唯一一局——胜利。

• 2017年末，AlphaZero 推出。学习过程是从随机比赛开始的，没有内置的领域知识，不受人类棋手规范的约束，只有游戏的基本规则。

• 系统会从输赢和平局中学习以调整神经网络的参数，使其更有可能在未来选择有利的动作。

• 网络所需的训练量取决于游戏的风格和复杂性，国际象棋大约需要 9 小时，将棋需要 12 小时，围棋需要13天。

AlphaGo





具身智能核心技术解析


Multi-Agent
Hide and Seek

具身智能核心技术解析


Boston Dynamics - Atlas



具身智能核心技术解析



具身智能核心技术解析




具身智能核心技术解析

S1 >>



S2 >>



S3 >>



具身智能核心技术解析

监督学习


- › 有标签数据
- › 直接反馈
- › 预测结果 / 未来

无监督学习


- › 无标签 / 目标
- › 无反馈
- › 寻找数据中隐藏的结构

强化学习

- › 决策过程
- › 奖励机制
- › 学习一系列的行动



(a) 监督学习




(b) 强化学习



(c) 非监督学习


具身智能核心技术解析

无监督学习:



具身智能核心技术解析

无监督学习:



具身智能中的AI技术

任务描述:



控制机器人移动手臂抓取目标物。
包括单物品抓取、多物品排障避障抓取。

其中桌子高度、目标物、障碍物位置在机器人手臂可达范围内随机设定。



观测空间:

1. 视觉: RGBD
2. 传感器: 机器人手臂关节角度



方案对比:

1. 传统方法是否可以解决问题?

在没有障碍物时,使用传统运动学方法也可以规划出合适的抓取轨迹,但是面对有障碍物的场景传统方法**难度和运算时间**都随着障碍物数据增加而急剧上升。

2. 强化学习的优势:

机械臂抓取是个**连续决策问题**,而强化学习是解决此类问题的优秀方法。强化学习的**主动探索**特性有利于学习到多物品排障的方法,且推理时用时固定,不受障碍物数量影响。


动作空间:

1. 上层策略: 待抓取位置坐标 + 目标位置坐标
2. 下层策略: 手臂关节角度

奖赏:

1. 稀疏奖励
 1. 成功: 抓取物品移动到目标位置
 2. 失败: 超时/碰撞
2. 稠密奖励
 1. 手掌靠近物品的奖赏
 2. 手掌抓取姿态的奖赏
 3. 物品距离目标点距离的奖赏

具身智能中的AI技术




具身智能中的AI技术

1. 优化状态空间：更多信息更易学习，筛选
2. 优化动作空间：离散比连续简单
3. 优化奖励函数：参考专家策略、利用仿真进行观察
4. 调整算法参数调整网络设计



问题1：抓取时手容易碰倒物品

解决方案：通过奖励引导手掌姿势（虎口方向 + 手的转向）



问题2：抓取轨迹不平滑

解决方案：通过奖励函数惩罚不平滑的轨迹



具身智能中的AI技术

虚实差异

1. 仿真可以获得全量信息（如物品3D信息，重心等），真实世界中难以获取
2. 仿真环境的RGBD图片和真实世界存在差异（光线、纹理等）
3. 真实世界中机器存在个体差异，比如延时、损耗

应对策略

1. 在设计观测时避免使用真实世界得不到的信息
2. 在训练时对RGBD图片进行增强处理，尽量模拟真实场景
3. 采用教师学生策略，先用全量信息在仿真中训练教师策略，再蒸馏得到使用真实世界的部分观测学习到学生策略。


具身智能中的AI技术

任务描述:

控制机器人底盘的线速度和角速度，使其从起始位置移动到目标位置，同时避开途中的静态、动态障碍物。

观测空间:

1. 视觉: 激光雷达 + 深度图
2. 本体感知: 角速度 + 线速度 + 位置



动作空间:

1. 角速度 + 线速度

奖赏:

1. 稀疏奖励
 1. 成功: 到达目标位置
 2. 失败: 超时/碰撞
2. 稠密奖励
 1. 奖励靠近目标位置的行为
 2. 惩罚超过理想最大角速度的行为
 3. 惩罚角速度变化过大的行为
 4. 惩罚距离障碍物小于0.2m的行为
 5. 惩罚前方视野范围0.5m内都是障碍物（墙）的行为


具身智能中的AI技术

运动轨迹点计算

A*算法

局部目标点

观测



激光雷达

+

深度图



当前位置信息



目标点相对位置

角速度

线速度

融合深度激光信息


栅格化激光信息
(每一度取最小值, 根据不同最短距离长度做不同厘米级别四舍五入)



1D
Conv

强化学习避障


特征融合



机器人
底盘线速度、角速度

基于人类反馈的强化学习与VLA

RLHF 人类反馈强化学习模型原理



基于人类反馈的强化学习与VLA



标注人员



Q:世界上最高的山是什么?
A:世界上最高的山是珠穆朗玛峰。

Q:请帮我写一个搞笑的段子。
A: 没问题，下面是一个段子，希望你能喜欢：



GPT3.5



调优后的模型

Step 1

**Collect demonstration data,
and train a supervised policy.**

A prompt is
sampled from our
prompt dataset.


Explain the moon
landing to a 6 year old

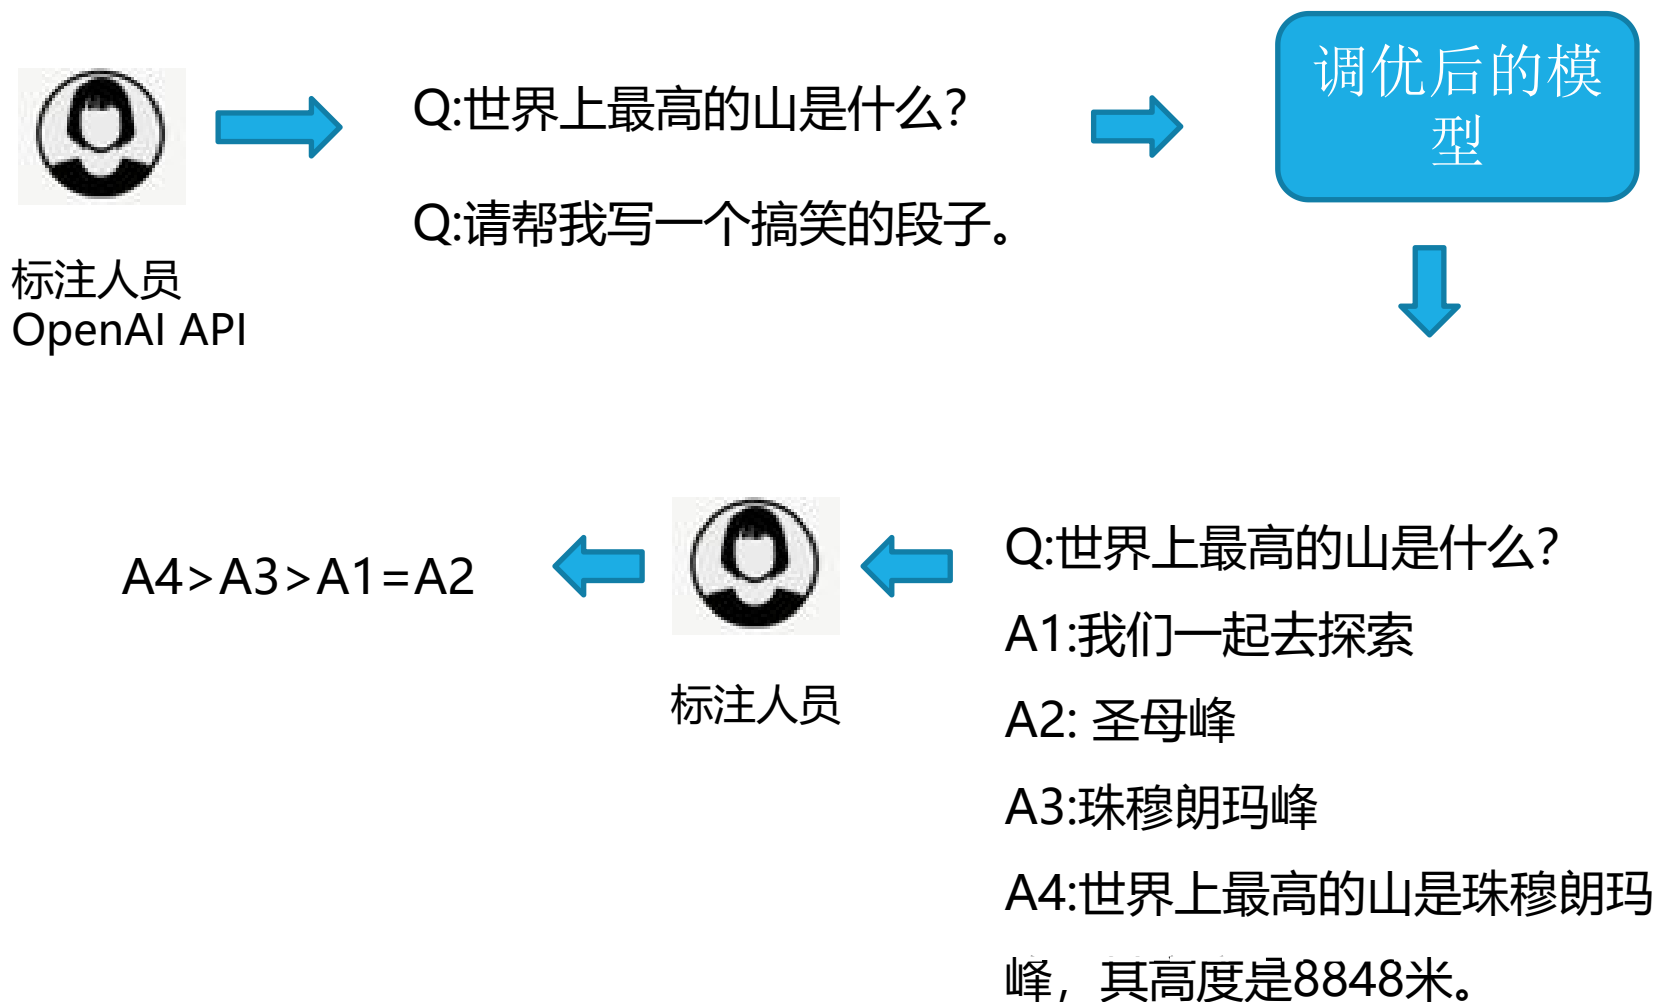
A labeler
demonstrates the
desired output
behavior.


Some people went
to the moon...

This data is used
to fine-tune GPT-3
with supervised
learning.


SFT



基于人类反馈的强化学习与VLA



Step 2

**Collect comparison data,
and train a reward model.**

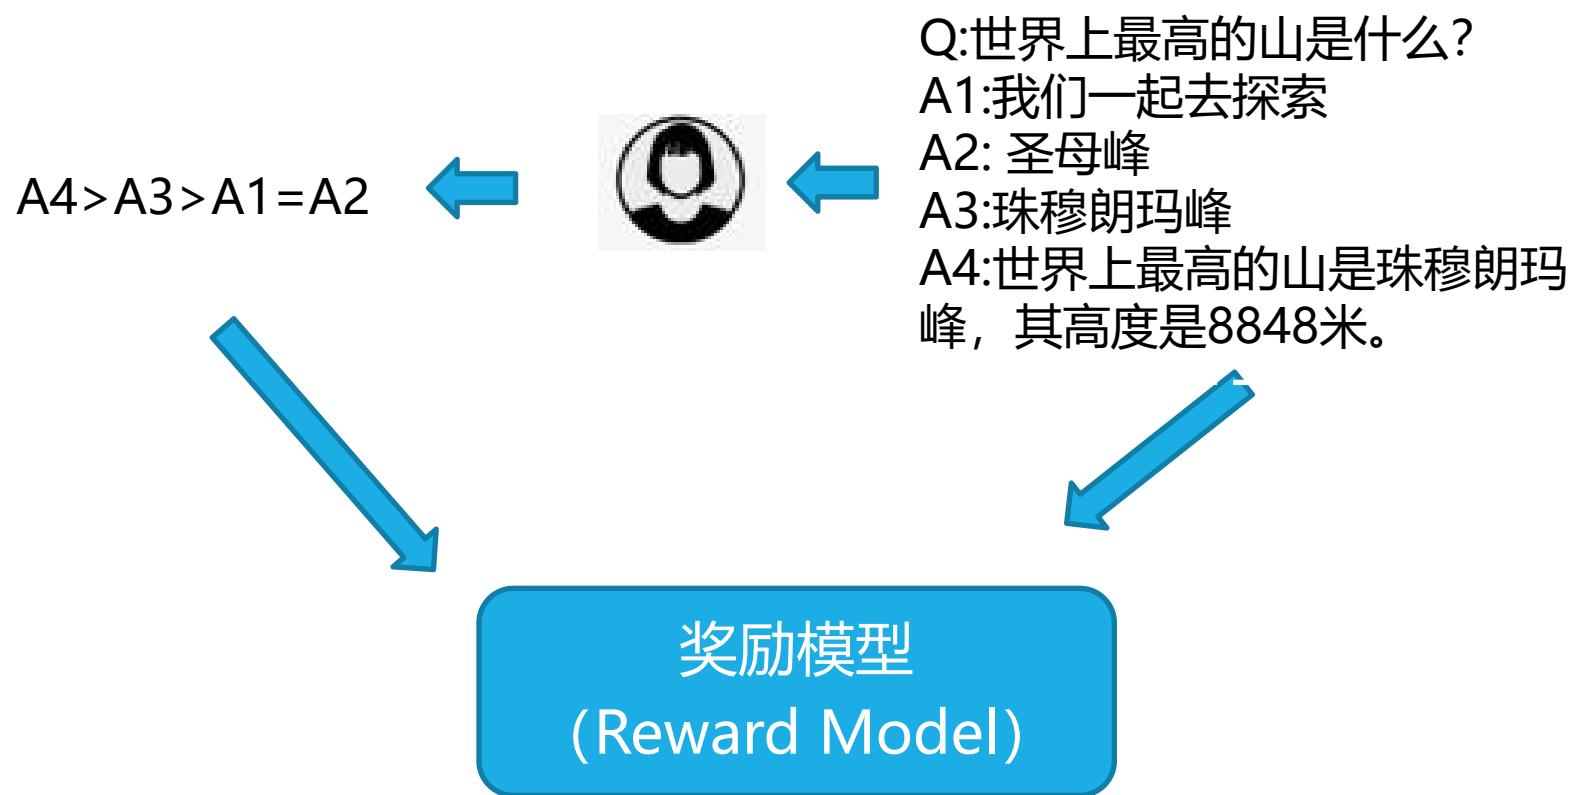
A prompt and
several model
outputs are
sampled.



A labeler ranks
the outputs from
best to worst.

This data is used
to train our
reward model.


基于人类反馈的强化学习与VLA



Step 2

**Collect comparison data,
and train a reward model.**

A prompt and
several model
outputs are
sampled.



基于人类反馈的强化学习与VLA

从OpenAI得到的问题集

Q:世界上最高的山是什么?


Q:请帮我写一个搞笑的段子。

Q:地球的半径是多少?

.....



世界上最高的山是什么?



Step 3


Optimize a policy against the reward model using reinforcement learning.

A new prompt is sampled from the dataset.

The policy generates an output.

The reward model calculates a reward for the output.

The reward is used to update the policy using PPO.



基于人类反馈的强化学习与VLA

Step 1

Collect demonstration data and train a supervised policy.


A prompt is sampled from our prompt dataset.



A labeler demonstrates the desired output behavior.



This data is used to fine-tune GPT-3.5 with supervised learning.




Step 2

Collect comparison data and train a reward model.


A prompt and several model outputs are sampled.



A labeler ranks the outputs from best to worst.



This data is used to train our reward model.




Step 3

Optimize a policy against the reward model using the PPO reinforcement learning algorithm.

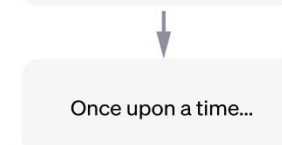
A new prompt is sampled from the dataset.




The PPO model is initialized from the supervised policy.




The policy generates an output.





The reward model calculates a reward for the output.




The reward is used to update the policy using PPO.



具身智能中的数据仿真环境



鼠标拖拽进行示教




体感设备进行示教

强化学习实践

Stable Baselines 是基于 OpenAI Baselines 的强化学习算法的增强实现。

Stable Baselines3 是 PyTorch 版本的 Stable Baselines，是强化学习算法的可靠实现。也称为SB3。

<https://stable-baselines.readthedocs.io/en/master/>



Stable Baselines

Docs » Welcome to Stable Baselines docs! - RL Baselines Made Easy [Edit on GitHub](#)

Warning

This package is in maintenance mode, please use [Stable-Baselines3 \(SB3\)](#) for an up-to-date version. You can find a [migration guide](#) in SB3 documentation.

Welcome to Stable Baselines docs! - RL Baselines Made Easy

[Stable Baselines](#) is a set of improved implementations of Reinforcement Learning (RL) algorithms based on OpenAI [Baselines](#).

Github repository: <https://github.com/hill-a/stable-baselines>

RL Baselines Zoo (collection of pre-trained agents): <https://github.com/araffin/rl-baselines-zoo>

RL Baselines zoo also offers a simple interface to train, evaluate agents and do hyperparameter tuning.

You can read a detailed presentation of Stable Baselines in the Medium article: [link](#)

master

Search docs


USER GUIDE

- Installation
- Getting Started
- Reinforcement Learning Tips and Tricks
- Reinforcement Learning Resources
- RL Algorithms
- Examples

强化学习实践

一阶倒立摆（Inverted Pendulum）是一种经典的控制系统实验装置，由一个安装在移动小车上的铰接摆杆组成。其主要特征是摆杆的重心位于其支点的上方，处于不稳定的平衡状态。控制任务是通过调节小车的移动来保持摆杆直立不倒，因此这是一个典型的非线性系统问题。

将CartPole的位置，速度，杆的角度，杆的角速度传入神经网络，神经网络输出动作的概率，这种向量输入，向量输出的模式，适合多层感知机而不是卷积网络，卷积网络一般是对图像信息进行操作。



强化学习实践

一阶倒立摆系统是强化学习的经典案例之一：

1. 问题的复杂性与可控性

一阶倒立摆是一个典型的非线性控制问题，虽然结构简单，但在控制难度上具有挑战性。其动态特性非常适合用于研究强化学习算法，因为需要不断地在复杂的状态空间中探索有效的策略来保持摆杆平衡。这种复杂性使得强化学习可以通过不断的试错和调整，优化策略来解决实际问题。

2. 明确的目标与奖励机制

在强化学习中，定义明确的奖励机制对于算法的学习至关重要。对于倒立摆系统，目标是让摆杆保持直立，因此可以轻松定义奖励函数：当摆杆接近直立时给予正奖励，而当摆杆倒下或偏离垂直方向时给予负奖励。这个明确的目标使得强化学习算法能够清楚地理解每个动作的好坏，从而逐步学会如何控制小车以保持平衡。

3. 状态和动作空间

一阶倒立摆的状态空间可以描述为摆杆的角度、角速度、小车的位置和速度。动作空间通常是小车的加速度或施加的力。由于状态和动作空间是连续的，这使得问题足够复杂，适合强化学习中处理连续状态和动作的算法，比如深度强化学习（Deep Reinforcement Learning, DRL）。

强化学习实践

4. 实时反馈与探索

倒立摆系统具有明确的实时反馈机制，这与强化学习的“探索-利用”（**exploration-exploitation**）策略高度匹配。通过探索不同的动作，强化学习算法可以学习到不同的策略，并通过反馈不断调整和优化，最终找到能够最大化累计奖励的最优策略。

5. 广泛的适应性

倒立摆问题虽然简单，但与许多实际应用场景类似，比如机器人平衡、无人车稳定、飞行器姿态控制等。通过在倒立摆上训练的强化学习算法和策略，理论上可以扩展和应用到其他具有相似控制需求的系统中。


总结

倒立摆系统提供了一个既复杂又可控的环境，非常适合用来测试和验证强化学习算法。其明确的奖励机制、连续的状态和动作空间、实时的反馈系统等特点，使其成为研究和开发强化学习算法的理想平台。因此，倒立摆案例在强化学习领域被广泛使用，是研究者们用来展示算法性能、理解算法行为、甚至作为教学演示的经典实验平台。

强化学习实践

```
1 import gym
2 import numpy as np
3
4 from stable_baselines3 import DQN
5 from stable_baselines3.dqn import MlpPolicy
6
7 env = gym.make('CartPole-v0')
8
9 model = DQN(MlpPolicy, env, verbose=1)
10 model.learn(total_timesteps=10000, log_interval=4)
11 model.save("dqn_pendulum")
12
13 obs = env.reset()
14 while True:
15     action, _states = model.predict(obs, deterministic=True)
16     obs, reward, done, info = env.step(action)
17     env.render()
18     if done:
19         obs = env.reset()
```

`pip install stable-baselines3`




<https://stable-baselines3.readthedocs.io/en/master/modules/dqn.html>

强化学习实践

设置`total_timesteps=10000` 对于训练来说是无济于事的，我们将其设置为30万，结果如下面动画，看起来效果还不是很好。

稳定性：如果倒立摆杆能够在垂直方向附近维持稳定，并且小车的移动范围较小，则可以认为控制效果较好。如果摆杆无法保持在垂直位置，并且有较大的摆动或小车运动幅度较大，则效果较差。

响应速度：摆杆从初始偏离到垂直位置的恢复时间越短，且无明显的过冲或震荡，说明系统的响应速度较好。




强化学习实践

稳态误差：当倒立摆达到平衡后，观察其是否存在持续的摆动或小幅振荡。如果摆杆能够保持在垂直附近并且无显著的振荡，说明系统的稳态误差较小，控制效果较好。

控制力大小：如果系统需要使用较大的力频繁调整小车的位置来保持摆杆平衡，说明控制系统的性能可能不足。


我们将其增加到100万，看一下效果。



强化学习实践


```
1 import gym
2 from stable_baselines3 import PPO
3
4 env=gym.make('CartPole-v0')
5 model=PPO('MlpPolicy',env,verbose=1)
6 model.learn(total_timesteps=500000)
7
8 obs=env.reset()
9 for i in range(9000):
10     action,_state=model.predict(obs,deterministic=True)
11     obs,reward,done,info=env.step(action)
12     env.render()
13     if done:
14         obs=env.reset()
```

用PPO算法试一下：



具身智能商业应用与未来趋势

具身智能 (Embodied Artificial Intelligence, 简称 EAI) 将人工智能融入机器人等物理实体, 赋予它们感知、学习和与环境动态交互的能力。想象一下与物理世界互动的机器人或虚拟助手。与人类一样, 这些智能体的心理构造受其身体的影响。那么, 这样的技术有一天能演变出意识吗?




具身智能商业应用与未来趋势

感知、思考、行动：机器人将计算转化为行动。


"具身" (Embodiment) 是一个心理学概念，基本含义是指认知对身体的依赖性，即身体对于认知具有影响。具身智能是指一种基于物理身体进行感知和行动的智能系统，其通过智能体与环境的交互获取信息、理解问题、做出决策并实现行动，从而产生智能行为和适应性。

想象一个未来，人工智能不仅仅只是限于数字领域，而是在我们的物理世界中移动、学习，与人类交互。人工智能的下一个巨大飞跃不仅仅是数字化，而是具身化。





具身智能商业应用与未来趋势

Atlas from Boston Dynamics



具身智能商业应用与未来趋势

Farewell to Hydraulic Atlas & Welcome New Atlas



具身智能商业应用与未来趋势

谷歌和柏林工业大学的团队曾推出了大型视觉语言模型——PaLM-E，参数量高达5620亿（GPT-3的参数量为1750亿）。

PaLM-E不仅可以理解图像，还能理解、生成语言，可以执行各种复杂的机器人指令而无需重新训练



具身智能商业应用与未来趋势

人机交互能力

- 识别
- 反馈
- 交互

环境感知能力


- 视觉
- 位置
- 听觉
- 触觉
- 嗅觉

运动控制能力

- 动力系统
- 关节机构
- 灵巧的手
- 旋转关节
- 线性关节



人形机器人：仿人形+三大核心技术能力



具身智能商业应用与未来趋势

Maxon	
型号	RE 16
示意图	
额定电压	12 V
空载转速	13900 rpm
额定转矩 (最大连续转矩)	4.36 mNm
电刷类型	石墨电刷
最大效率	79%
重量	40 g
价格	¥1,483 (电机价格)

单侧灵巧手:
6个空心杯电机



特斯拉Optimus方案

灵巧手预计采用空心杯电机+蜗轮蜗杆的设计方案，单手共有6个执行器（包含6个空心杯电机，每个手指一个/拇指两个），共11个自由度，可使用工具，实现小物体的准确抓取，举起20磅的重量。



具身智能商业应用与未来趋势

自21年8月特斯拉首次发布人形机器人概念机以来，不到2年时间，实现了机器人开发平台的搭建及机器人性能的持续迭代。

目前已经实现了直立行走、搬运物体、洒水等复杂任务，是机器人在AI训练、环境感知、精确控制等方面底层技术不断革新，不断接近能够现实应用的目标。



Optimus最新公布参数

高：173cm

重：63kg

灵活度：关节数50

负重：可拿取约20千克重物品

行走速度：（概念机）最快8英里/h


耗电量：静坐100W；慢走500W

应用场景：首先应用于特斯拉工厂，长期目标为进入社会应用及家庭生活场景

具身智能商业应用与未来趋势


针对特斯拉机器人方面的最新进展，马斯克表示，我们可以通过一些编程和指令，从人形机器人身上获取更大的价值。特斯拉机器人已经可以“自己造自己”了。

未来，人形机器人会应用于更多的工业场景中，人类和人形机器人的比例可能会大于1:1。



具身智能商业应用与未来趋势

特斯拉发布Optimus Gen2， Optimus Gen2对颈部、灵巧手以及足部做了升级，使得全身平衡运动能力提升的同时，手部的灵活性 以及双手的协调性也得到了很大的提升，距离将来走入工厂使用各种生产工具进行操作的能力进一步提升。



距离走进生产线更近一步



总装车间-汽车底盘装配



总装车间-汽车零部件检测

具身智能商业应用与未来趋势



智元机器人的基本介绍

基本信息

身高170cm，体重55kg，步行速度7km/h，
承重80kg，单臂最大负载5kg。

特点

1. 具备多模态感知、少样本学习、任务闭环、强人机交互能力。
2. 自研关节电机PowerFlow、灵巧手SkillHand、**反曲膝设计**等关键零部件。



宇树H1人形机器人的基本介绍

基本信息

身高180cm，体重47kg，步行速度
>1.5m/s，潜在运动能力>5m/s。

特点

1. 自由度：单腿5（髋*3+膝*1+踝*1）*2+单臂4*2+灵巧手选配（在研）。
2. 搭配自研M107关节电机，峰值扭矩密度89Nm/kg，最大关节扭矩360Nm，采用中空走线。

具身智能商业应用与未来趋势

傅利叶人形机器人GR-1 简介:

身高165cm，体重55kg，44个自由度，32个FSA关节，最大模组峰值扭矩230Nm，自研一体化执行器，拟人直腿行走，自适应平衡算法避障上下坡抗干扰。



达闼科技人形机器人小紫XR-4 简介:



基本信息

身高1.68米，体重65KG，有60个以上的智能柔性关节，步行速度将为5公里/小时。

阶段

目前小紫的研发还处于第二阶段。双足目前主要能实现站和走路的功能，其他还都处于开发阶段

具身智能商业应用与未来趋势

小米科技人形机器人 CyberOne 简介:



基本信息

身高1.77米，重52kg；支持21个自由度，动力峰值扭矩300Nm，峰值扭矩密度96Nm/kg；速度3.6km/h


特点:

- 自研Mi-Sense深度视觉模组，敏锐的下视觉，三维重建真实世界8米内深度信息精度可达1%，辨别85种环境语义，45种人类语义情绪。
- 尚未实现量产

科大讯飞人形机器人样机:



具身智能商业应用与未来趋势



具身智能商业应用与未来趋势

具身智能的能力提升需要从交互中自主学习。在真实物理世界中对机器人进行训练，存在着数据采集效率低下、复用性差、训练风险高、评测困难等诸多瓶颈，因而，将在虚拟环境训练成果应用于真实环境的“虚实迁移”（Simulation-to-Real）技术，成为当前具身智能领域的重点研究方向之一。



具身智能商业应用与未来趋势

桃源仿真平台可模拟各种复杂场景和机器人的行为模式，包括但不限于户外作业、社交互动、家庭生活、工业生产、商业交易等，从而为具身智能体提供了具有社会属性的虚拟社会。该平台包含海量高质量可交互场景数据，并可借助AIGC技术生成多样化、难度适中的具身智能任务，建立相应的评测体系，赋能具身智能大模型研发。




具身智能中的数据仿真环境



仿真环境效果展示

具身智能中的数据仿真环境



- 15个精模室内场景，7个大范围的室外场景。
- 10K+数量的模型，包括鞋子，水壶，水杯，药盒，采摘筐，餐盘，筷子，碗，夹子，搅拌棒，毛巾，行李箱，咖啡机，制冰机，电视，灯，吸尘机，洗地机，书籍，国际象棋，冰箱（单开\双开）+把手 内部抽屉等等
- 机器人种类：Ginger（人型机器人），XR4（双足），GingerLite（送餐机器人），采摘机器人，巡检机器人，野外巡逻机器人，协作机械臂，pepper机器人等。
- 其中Ginger机器人有34个关节，可分别控制运动；
- 机器人底盘运动提供速度控制，位置控制，导航移动等多个接口；
- 支持RGB，Depth，segment相机，激光雷达，IMU，里程计等传感器。





仿真环境效果展示

具身智能中的数据仿真环境



支持场景展示



具身智能中的数据仿真环境



具身智能中的数据仿真环境



主要接口:

- **Reset:** 重置环境
- **Observe:** 获取环境中的观测，包括物品位置、包围盒、智能体自身关节角度信息等
- **MakeObjects:** 在环境中添加物品，指定位置及种类
- **Capture:** 获取智能体上RGBD相机的数值
- **Rotate:** 控制智能体手臂关节角度
- **Grasp/Release:** 控制智能体手指开/合
- **Walk:** 控制智能体底盘移动

RDK仿真环境简介——使用Action接口实现导航示例

接口名称: GrabSim_pb2.Action

参数名称	参数含义	取值类型	取值示例
sceneID	场景ID	int	0, 1, 2...
action	动作类型	Action.ActionType	WalkTo（导航至某点） RotateJoints（旋转关节）
values	动作取值	list of float	1. 动作类型WalkTo 取值:[目标点坐标x，目标点坐标y，目标转向角度，运动速度， 导航点距离目标点的距离阈值] 2. 动作类型RotateJoints 取值: 按照关节序号排列的关节旋转绝对角度[0， 0， 0， ...]

RDK仿真环境简介——使用Action接口实现导航示例

示例：用不同速度导航到某个点

```
import grpc

import GrabSim_pb2
import GrabSim_pb2_grpc

channel = grpc.insecure_channel('127.0.0.1:30001',
                                options=[('grpc.max_send_message_length', 1024 * 1024 * 1024),
                                           ('grpc.max_receive_message_length', 1024 * 1024 * 1024)])
sim_client = GrabSim_pb2_grpc.GrabSimStub(channel)

# init & reset
scene = sim_client.Init(GrabSim_pb2.Count(value=1))

# walk in different volicity|
for i in range(2):
    scene = sim_client.Reset(GrabSim_pb2.ResetParams(sceneID=0))

    # observe
    scene = sim_client.Observe(GrabSim_pb2.SceneID(value=0))
    cur_position = [scene.location.X, scene.location.Y, scene.rotation.Yaw]
    print("current position:", cur_position)

    # walk
    walk_v = [-1525, -1515, 270, 250 * (i + 1), 1]
    action = GrabSim_pb2.Action(sceneID=0, action=GrabSim_pb2.Action.ActionType.WalkTo, values=walk_v)
    scene = sim_client.Do(action)
    print(scene.info) # print navigation info
    time.sleep(8)
```





机器人抓取实践

任务描述:

控制机器人移动手臂抓取目标物。

包括单物品抓取、多物品排障避障抓取。



其中桌子高度、目标物、障碍物位置在机器人手臂可达范围内随机设定。



观测空间:

1. 视觉: RGBD

2. 传感器: 机器人手臂关节角度



方案对比:

1. 传统方法是否可以解决问题?

在没有障碍物时, 使用传统运动学方法也可以规划出合适的抓取轨迹, 但是面对有障碍物的场景传统方法**难度和运算时间**都随着障碍物数据增加而急剧上升。

2. 强化学习的优势:

机械臂抓取是个**连续决策问题**, 而强化学习是解决此类问题的优秀方法。强化学习的**主动探索**特性有利于学习到多物品排障的方法, 且推理时用时固定, 不受障碍物数量影响。

动作空间:

1. 上层策略: 待抓取位置坐标 + 目标位置坐标

2. 下层策略: 手臂关节角度

奖赏:


1. 稀疏奖励

1. 成功: 抓取物品移动到目标位置
2. 失败: 超时/碰撞

2. 稠密奖励

1. 手掌靠近物品的奖赏
2. 手掌抓取姿态的奖赏
3. 物品距离目标点距离的奖赏

机器人抓取实践




机器人抓取实践

1. 优化状态空间：更多信息更易学习，筛选
2. 优化动作空间：离散比连续简单
3. 优化奖励函数：参考专家策略、利用仿真进行观察
4. 调整算法参数调整网络设计



问题1：抓取时手容易碰倒物品

解决方案：通过奖励引导手掌姿势（虎口方向 + 手的转向）




问题2：抓取轨迹不平滑

解决方案：通过奖赏函数惩罚不平滑的轨迹



机器人抓取实践



机器人抓取实践


虚实差异

1. 仿真可以获得全量信息（如物品3D信息，重心等），真实世界中难以获取
2. 仿真环境的RGBD图片和真实世界存在差异（光线、纹理等）
3. 真实世界中机器存在个体差异，比如延时、损耗

应对策略

1. 在设计观测时避免使用真实世界得不到的信息
2. 在训练时对RGBD图片进行增强处理，尽量模拟真实场景
3. 采用教师学生策略，先用全量信息在仿真中训练教师策略，再蒸馏得到使用真实世界的部分观测学习到学生策略。

机器人抓取实践



强化学习抓取真机测试效果


强化学习避障与导航

任务描述:

控制机器人底盘的线速度和角速度，使其从起始位置移动到目标位置，同时避开途中的静态、动态障碍物。

观测空间:

1. 视觉: 激光雷达 + 深度图
2. 本体感知: 角速度 + 线速度 + 位置



动作空间:

1. 角速度 + 线速度

奖赏:

1. 稀疏奖励
 1. 成功: 到达目标位置
 2. 失败: 超时/碰撞
2. 稠密奖励
 1. 奖励靠近目标位置的行为
 2. 惩罚超过理想最大角速度的行为
 3. 惩罚角速度变化过大的行为
 4. 惩罚距离障碍物小于0.2m的行为
 5. 惩罚前方视野范围0.5m内都是障碍物（墙）的行为


强化学习避障与导航

运动轨迹点计算

A*算法

局部目标点

观测



激光雷达

+

深度图



当前位置信息



目标点相对位置

角速度

线速度

融合深度激光信息

栅格化激光信息
(每一度取最小值, 根据不同最短距离长度做不同厘米级别四舍五入)



1D
Conv




强化学习避障

特征融合


PPO算法

机器人
底盘线速度、角速度

强化学习避障与导航



强化学习避障与导航




采摘强化训练



采摘任务强化训练仿真环境能力

采摘强化训练



采摘第一剪前观察任务



采摘第一剪训练任务